

Clasificación supervisada de enfermedad hepática mediante técnicas de aprendizaje automático

Jefferson Andrés Espejo-Goez, Diego Alejandro Vásquez-Aguilar
Modelos y Simulación de Sistemas II

Resumen—Este trabajo aborda la formulación y evaluación de un sistema de apoyo para la clasificación de enfermedad hepática (entre ellas hepatitis C) a partir del conjunto de datos HCV del repositorio UCI [1]. El objetivo es analizar el desempeño de distintos modelos supervisados bajo formulaciones multiclase y binaria, considerando el fuerte desbalance presente en las categorías clínicas. El conjunto contiene 615 registros, 12 variables predictoras de tipo demográfico y bioquímico, una variable objetivo con cinco categorías clínicas y valores faltantes concentrados en un subconjunto pequeño de atributos. Se implementaron estrategias de preprocesamiento, imputación robusta, balanceo mediante SMOTE y ADASYN, y exploración de la posibilidad de reducción de dimensionalidad utilizando PCA y UMAP. Los resultados muestran que los modelos basados en Random Forest combinados con técnicas de sobremuestreo presentan el mejor desempeño, especialmente en la formulación binaria, donde se alcanzaron valores de F_1 macro superiores a 0.94 y AUC-ROC cercanos a 1.0. Adicionalmente, los experimentos de extracción de características evidenciaron que el conjunto original conserva información discriminativa relevante y que la reducción dimensional no produjo mejoras consistentes en el escenario multiclase.

Index Terms—hepatitis C, machine learning, aprendizaje supervisado, clasificación, datos clínicos, UCI

I. INTRODUCCIÓN

La hepatitis C es una enfermedad de interés clínico debido a que puede evolucionar desde estados iniciales con pocos síntomas hasta fibrosis, cirrosis y daño hepático severo. En este contexto, el uso de modelos de aprendizaje automático sobre datos de laboratorio puede servir como herramienta de apoyo para identificar patrones que faciliten la clasificación de pacientes, la priorización de estudios y la exploración de factores asociados a la enfermedad.

II. DESCRIPCIÓN DEL PROBLEMA

II-A. Contexto del problema

El problema de interés consiste en clasificar registros de pacientes potenciales donantes de sangre a partir de variables demográficas y pruebas bioquímicas relacionadas con función hepática. Una solución basada en aprendizaje automático es pertinente porque el conjunto de datos contiene etiquetas conocidas, variables clínicas estructuradas y patrones no triviales entre biomarcadores, lo que permite construir modelos de clasificación con potencial utilidad como apoyo a la decisión.

La utilidad práctica de este tipo de sistema radica en tres puntos. Primero, puede apoyar el tamizaje inicial de pacientes con alteraciones compatibles con hepatitis C. Segundo,

Tabla I
VARIABLES DEL DATASET HCV

Variable	Tipo	Descripción
Category	Categ.	Diagnóstico o condición clínica del registro.
Age	Num.	Edad del paciente.
Sex	Categ.	Sexo reportado en el registro.
ALB	Num.	Albúmina.
ALP	Num.	Fosfatasa alcalina.
ALT	Num.	Alanina aminotransferasa.
AST	Num.	Aspartato aminotransferasa.
BIL	Num.	Bilirrubina.
CHE	Num.	Colinesterasa.
CHOL	Num.	Colesterol.
CREA	Num.	Creatinina.
GGT	Num.	Gamma-glutamyl transferasa.
PROT	Num.	Proteínas totales.

permite comparar qué tan informativas son distintas pruebas de laboratorio en la separación de clases clínicas. Tercero, ofrece una base reproducible para analizar si una formulación binaria o multiclase resulta más conveniente bajo condiciones de desbalance y presencia de datos faltantes. En cualquier caso, el modelo debe entenderse como una herramienta de apoyo y no como un sustituto del criterio médico.

II-B. Composición de la base de datos

Se utilizará el conjunto *HCV data* del repositorio UCI [1]. En el archivo CSV validado para este proyecto se identifican 615 registros y 13 columnas útiles: 12 variables predictoras y la variable objetivo *Category*. En la exportación original también puede aparecer una primera columna vacía asociada al índice del archivo; dicha columna no contiene información clínica y será eliminada antes del modelado.

La Tabla I resume las variables del conjunto. Las variables *Age* y *Sex* corresponden a información demográfica, mientras que las demás representan pruebas bioquímicas relacionadas con el estado del hígado y el metabolismo del paciente.

La variable objetivo presenta cinco categorías clínicas:

- 0=Blood Donor: 533 registros.
- 0s=suspect Blood Donor: 7 registros.
- 1=Hepatitis: 24 registros.
- 2=Fibrosis: 21 registros.
- 3=Cirrhosis: 30 registros.

Esta distribución evidencia un desbalance severo, ya que la clase *Blood Donor* concentra la gran mayoría de observaciones. Por tanto, cualquier metodología posterior debe evitar

que la exactitud global esconda un mal desempeño sobre las clases minoritarias.

En cuanto a valores faltantes, el archivo presenta ausencias en cinco atributos numéricos: ALB (1), ALP (18), ALT (1), CHOL (10) y PROT (1). No se observan faltantes en la variable objetivo ni en los demás atributos. Dado que se trata de variables continuas de laboratorio y el conjunto contiene clases pequeñas, se propone imputación por la mediana calculada exclusivamente sobre el conjunto de entrenamiento. Esta decisión busca reducir la sensibilidad a valores extremos y evitar fuga de información en las etapas de validación o prueba.

Respecto a la codificación, se adoptará el siguiente criterio:

- La columna índice vacía del CSV, si aparece, se eliminará.
- Sex se codificará de forma binaria para el modelado.
- Category se tratará como variable nominal. Para uso computacional se asignarán etiquetas enteras a cada clase, pero dichas etiquetas funcionarán solo como identificadores y no como valores ordinales continuos.
- Las variables bioquímicas se conservarán como numéricas continuas.

II-C. Paradigma de aprendizaje y justificación

El problema se formula como una tarea de clasificación supervisada porque cada registro cuenta con una etiqueta conocida en la variable `Category`. La naturaleza tabular del conjunto, el número moderado de variables y la combinación de atributos demográficos y clínicos hacen apropiado el uso de clasificadores supervisados tradicionales y modernos.

La formulación principal del proyecto será **multiclase**, ya que respeta la estructura original del dataset y permite distinguir entre donantes, pacientes sospechosos, pacientes con hepatitis, pacientes con fibrosis y pacientes con cirrosis. Esta formulación es más exigente, pero también más fiel al problema clínico representado por los datos. De forma complementaria, se considerará una formulación **binaria** en la que `Blood Donor` y `suspect Blood Donor` se agrupen como clase de pacientes sin enfermedad hepática, mientras que `Hepatitis`, `Fibrosis` y `Cirrhosis` se agrupen como clase de pacientes con enfermedad hepática. Esta segunda formulación será útil para comparar los resultados propios con trabajos de la literatura que reducen el problema a dos clases.

Esta decisión metodológica se justifica por tres razones. Primero, el conjunto de datos ya proporciona etiquetas y una interpretación clínica clara para cada observación. Segundo, existe un desbalance importante entre clases, por lo que interesa evaluar modelos que puedan mantener sensibilidad sobre clases minoritarias sin degradar demasiado el desempeño global. Tercero, la coexistencia de una formulación multiclase y una binaria permite analizar el compromiso entre fidelidad clínica y facilidad de clasificación, lo que enriquece la interpretación posterior de resultados.

III. ESTADO DEL ARTE

El problema de predicción del estado de infección por hepatitis C ha sido ampliamente abordado en la literatura mediante técnicas de aprendizaje automático, principalmente

bajo un paradigma de aprendizaje supervisado, utilizando datos clínicos estructurados como los del dataset HCV del repositorio UCI [1]. Los trabajos revisados consideran tanto formulaciones binarias como multiclase, dependiendo del nivel de detalle clínico y del tratamiento del desbalance de clases previamente discutido.

En [2], se propone un enfoque híbrido que combina aprendizaje no supervisado y supervisado, donde se emplea una etapa de pre-clustering para transformar las características antes de aplicar un modelo de stacking. Esta estrategia busca mejorar la separabilidad de las clases mediante representaciones más informativas. La validación se realiza mediante experimentación comparativa, utilizando métricas como accuracy, mostrando mejoras frente a modelos tradicionales.

Por otro lado, en [3] se aborda la predicción de supervivencia en pacientes con hepatitis mediante un enfoque de clasificación supervisada, evaluando modelos como Regresión Logística, Árboles de Decisión, Random Forest y KNN. La metodología se basa en la división del conjunto de datos en entrenamiento y prueba, así como en el análisis del impacto del desbalance de clases. Se emplean métricas como accuracy, precision y recall, evidenciando que modelos de ensamble como Random Forest presentan mejor desempeño en datos balanceados.

En [4], se introduce un enfoque basado en Automated Machine Learning (AutoML), que automatiza la selección de modelos y la optimización de hiperparámetros dentro de un marco supervisado. La validación se realiza mediante comparación entre múltiples configuraciones, utilizando métricas estándar como accuracy, precision, recall y F1-score. Los resultados muestran que AutoML logra desempeños competitivos, reduciendo la necesidad de intervención manual en el proceso de modelado.

Asimismo, en [5] se comparan distintos modelos supervisados, incluyendo Regresión Logística, Árboles de Decisión, Random Forest, KNN y Gradient Boosting, aplicados a datos clínicos con desbalance de clases. El estudio incorpora técnicas de balanceo como SMOTE-ENN, combinadas con Random Forest, para mejorar la clasificación de clases minoritarias. La evaluación se realiza mediante métricas como accuracy, reportando mejoras significativas en el desempeño del modelo tras el tratamiento del desbalance.

Finalmente, en [6] se emplea directamente el dataset HCV del repositorio UCI, utilizando modelos de ensamble como Random Forest, AdaBoost y XGBoost, junto con técnicas de balanceo como ADASYN (*Sobremuestreo Sintético Adaptativo*), es una técnica de sobremuestreo derivada de SMOTE que genera muestras sintéticas de manera adaptativa para las clases minoritarias. En problemas multiclase desbalanceados, ADASYN crea una mayor cantidad de ejemplos en las regiones donde la clasificación es más compleja, ayudando al modelo a mejorar el aprendizaje de clases con menor representación y fronteras de decisión difíciles). La metodología incluye preprocesamiento, normalización y evaluación comparativa entre modelos en escenarios balanceados y desbalanceados. Los resultados evidencian que Random Forest alcanza el mejor desempeño tras el balanceo de datos, mientras que XGBoost muestra robustez en escenarios desbalanceados.




Figura 1. Flujo de preprocesamiento encapsulado en el ColumnTransformer. La rama categórica aplica imputación por moda y OneHotEncoder; la rama numérica aplica imputación por mediana y StandardScaler. La matriz resultante alimenta la etapa de balanceo (SMOTE/ADASYN) y el clasificador dentro del Pipeline de imbalanced-learn.

En conjunto, los trabajos revisados coinciden en que los métodos de ensamble y las técnicas de balanceo de datos son fundamentales para mejorar el desempeño en la predicción de hepatitis C, especialmente debido al desbalance de clases y la complejidad de las relaciones entre variables clínicas.

IV. ENTRENAMIENTO Y EVALUACIÓN DE MODELOS

IV-A. Configuración experimental

Se realiza una partición estratificada entrenamiento-prueba 0.8-0.2 con semilla fija (`random_state=98`), preservando la proporción de cada clase. La validación de hiperparámetros se realiza dentro del conjunto de entrenamiento mediante validación cruzada estratificada. En la formulación multiclase se emplea `RepeatedStratifiedKFold` con 3 particiones y 5 repeticiones (15 mediciones por configuración), elección motivada por el tamaño reducido de la clase `suspect Blood Donor` (sólo 7 registros). En la formulación binaria, donde la clase minoritaria alcanza 76 registros tras agrupar, se emplea `StratifiedKFold` con 5 particiones.

El preprocesamiento se encapsula en un `ColumnTransformer` con dos ramas: para las variables categóricas, imputación con moda y `OneHotEncoder`; para las numéricas, imputación con mediana y `StandardScaler` (Fig. 1). El balanceo se aplica únicamente sobre el conjunto de entrenamiento de cada fold (encapsulado en un `Pipeline` de `imbalanced-learn`) para evitar fuga de datos de validación. Se emplearon y compararon dos estrategias de sobremuestreo SMOTE y ADASYN; en la formulación multiclase se utiliza una estrategia de muestreo evaluada *fold a fold* (`sampling_strategy callable`) que sobremuestra cada clase presente hasta 30 ejemplos con $k_{neighbors} = 1$, evitando errores de “clase ausente” en folds donde una clase minoritaria no aparece tras la partición.

Tabla II
MALLAS DE HIPERPARÁMETROS PARA CADA MODELO (FORMULACIÓN MULTICLASE).

Modelo	Hiperparámetro	Valores
Logit	C solver	{0,01, 0,1, 1, 10, 100} lbfgs, newton-cg, newton-cholesky, sag, saga
k-NN	n_neighbors weights	{5, 7, 9, 11, 15, 21} {uniform}
RF	n_estimators max_depth min_samples_leaf max_features	{100, 200, 500} {5, 7, 9, None} {2, 5, 10} {sqrt}
SVC	C kernel gamma	{0,01, 0,1, 1, 10, 100} linear, poly, rbf, sigmoid scale, auto
MLP	hidden_layer_sizes activation alpha	{{(10,), (20,), (30,)} tanh, relu {0,1, 1, 10}
HGB	max_iter learning_rate max_depth l2_regularization min_samples_leaf	{100, 200} {0,01, 0,05} {3} {10, 100} {30, 50, 80}
BRF	(misma malla que RF)	—

La métrica principal de selección es F_1 **macro** porque trata a las clases con igual peso, lo que es crítico bajo el escenario de desbalance severo presente el conjunto de datos. Adicionalmente se reporta *precisión balanceada* (promedio de *recall* por clase), *accuracy* (para contextualizar frente a la línea de base de la clase mayoritaria, 86.67 %), F_1 , *precision* y *recall* macro, y en la formulación binaria el AUC-ROC. Para diagnosticar sobreajuste se reporta la brecha (*gap*) entre F_1 macro de entrenamiento y prueba.

La Tabla II resume las mallas de hiperparámetros evaluadas con `GridSearchCV` (parámetros de evaluación = F_1 macro). Las mallas reflejan ajustes iterativos para mitigar el sobreajuste detectado en versiones tempranas: para Random Forest se exige $\text{min_samples_leaf} \geq 2$ y $\text{max_features} = \text{sqrt}$; en el Perceptrón Multicapa (MLP) se limita la red a una única capa oculta con $\alpha \geq 0,1$; en Gradient-Boosting basado en Histogramas (HGB) se acota la profundidad y $\text{min_samples_leaf} \geq 30$ con *parada anticipada activa* (*early stopping*); en k-vecinos más cercanos (k-NN) se restringe a $\text{weights} = \text{uniform}$.

IV-B. Resultados — formulación multiclase

La Tabla III consolida el desempeño en el conjunto de prueba para cada combinación modelo + estrategia de balanceo, junto con el F_1 macro promedio en validación cruzada (referencia para el cálculo de intervalos de confianza, sección IV-D). Los siete modelos se combinaron con las estrategias SMOTE y ADASYN y fueron consecuente entrenados, excepto Random Forest Balanceado (BRF), que realiza balanceo nativo por árbol y no requiere remuestreo. El mejor desempeño en test corresponde a Random Forest + ADASYN,




Figura 2. Desempeño vs. sobreajuste por modelo (multiclase). Eje x : gap F_1 macro train–test (mayor = más sobreajuste). Eje y : F_1 macro en test. La región ideal es la esquina superior izquierda (alto F_1 , gap pequeño).

con F_1 macro test $\approx 0,80$, precisión balanceada $\approx 0,77$ y una brecha entrenamiento-prueba prácticamente nula ($-0,008$).

El reporte por clase del mejor modelo (RF ADASYN) muestra que se reconoce perfectamente la clase *suspect Blood Donor* (recall=1.0 con un solo ejemplo en test), con 100 % de precisión en *Hepatitis* (recall=0.20, 5 ejemplos), 80 % precisión y 100 % recall en *Fibrosis* y 100 % precisión y 67 % recall en *Cirrhosis*; la clase *Blood Donor* se predice con 96 % precisión y 100 % recall.

Los modelos no lineales más expresivos (MLP, HGB) presentan brechas entrenamiento-prueba superiores a 0.25, indicando posible sobreajuste (Fig. 2). La regresión logística y el máquina de vectores de soporte (SVC) con kernel lineal muestran las menores brechas, sugiriendo que la frontera de decisión efectiva es razonablemente lineal en el espacio estandarizado. Random Forest con ADASYN alcanza un mejor balance entre desempeño en prueba y menor grado de sobreajuste; su curva de aprendizaje (Fig. 3) confirma que el entrenamiento y la validación convergen al aumentar el tamaño del conjunto de entrenamiento, sin signos de sobreajuste residual. Las matrices de confusión de los tres mejores modelos (Fig. 4) muestran que RF ADASYN distribuye mejor los aciertos entre clases minoritarias, mientras que SVC concentra la predicción en *Blood Donor*.

IV-C. Resultados — formulación binaria

La Tabla IV resume el desempeño de los cinco modelos en la formulación binaria. La métrica AUC-ROC se incluye porque el abordaje de clasificación binaria lo permite. Random Forest (+ SMOTE o ADASYN) y k-NN + SMOTE alcanzan los mejores F_1 macro en test ($\approx 0,94$ – $0,95$), con AUC-ROC superior a 0.99.

La formulación binaria es notablemente más sencilla de abordar porque elimina la distinción entre subtipos de enfermedad hepática (*Hepatitis*, *Fibrosis*, *Cirrhosis*), lo que aumenta la separabilidad y reduce un poco el efecto del desbalance: la clase minoritaria pasa de 7 ejemplos en *suspect Blood Donor* a 76 ejemplos en *enfermo*. Las curvas ROC superpuestas (Fig. 10) muestran AUC superiores a 0.99 para los cinco mejores modelos, indicando que la




Figura 3. Curva de aprendizaje del mejor modelo (RF ADASYN, multiclase). Eje x : número de muestras de entrenamiento. Eje y : F_1 macro. Bandas: $\pm 1\sigma$ sobre 5 folds.

separación entre sano y enfermo es prácticamente perfecta en el espacio de características. Las matrices de confusión de los tres mejores modelos (Fig. 5) muestran sólo 1–2 errores de la clase enfermo en test.

IV-D. Intervalos de confianza sobre la validación cruzada

Para cumplir el requisito de reportar IC sobre las medidas de desempeño *durante la fase de validación*, se ejecuta `cross_validate` sobre el `best_estimator_` obtenido por cada `GridSearchCV`, reusando el mismo objeto `cv` (RepeatedStratifiedKFold 3×5 en multiclase, $n = 15$; StratifiedKFold con 5 particiones en binaria, $n = 5$) y un `scoring dict` con todas las métricas relevantes: F_1 macro, balanced accuracy, accuracy y precision macro en la formulación multiclase, y F_1 macro, balanced accuracy, F_1 enfermo y AUC-ROC en la binaria. A partir de los scores por fold se estima un intervalo al 95 % con la distribución t-Student de $n - 1$ g.l.:

$$\bar{x} \pm t_{n-1, 0,975} \frac{s}{\sqrt{n}}, \quad (1)$$

con $\bar{x}$ media y s desviación estándar muestral por fold. Estos IC aparecen integrados en las tablas III y IV. En multiclase el ancho típico es del orden de $\pm 0,05$; en binario es mayor ($\pm 0,07$ a $\pm 0,15$) por el menor número de folds y se recortan a 1.000 los límites superiores que la aproximación gaussiana empuja por encima del rango admisible de las métricas acotadas.

V. SELECCIÓN Y EXTRACCIÓN DE CARACTERÍSTICAS

V-A. Análisis individual de características

Se realiza un análisis exploratorio de correlación entre variables evaluando inicialmente el coeficiente de correlación (lineal) de Pearson. Los resultados mostraron que ninguna pareja de variables superó un umbral de correlación absoluta de 0.7, por lo que no se identificaron evidencias graves/severas de colinealidad. Adicionalmente, se utiliza el índice discriminativo de Información mutua evaluado en los datos de entrenamiento, que permite evaluar el grado de dependencia estadística entre un par de variables/características, en este caso entre cada característica y la respuesta. Las variables AST,

Tabla III

DESEMPEÑO DE LOS MODELOS EN LA FORMULACIÓN MULTICLASE, ORDENADOS POR F_1 MACRO TEST (DESCENDENTE). LAS MÉTRICAS DE VALIDACIÓN SE REPORTAN COMO *media* $[IC_{INF}, IC_{SUP}]$ AL 95 % CON T-STUDENT DE 14 G.L. SOBRE 15 FOLDS (REPEATEDSTRATIFIEDKFOLD 3×5). EL *recall* MACRO COINCIDE NUMÉRICAMENTE CON LA PRECISIÓN BALANCEADA.

Modelo	Validación cruzada (con IC 95 %)				Train / Test			
	F_1 macro	Bal. Acc	Accuracy	Prec. macro	F_1 Tr.	F_1 Te.	B.A. Te.	Acc Te.
RF ADASYN	0.581 [0.529, 0.632]	0.551 [0.500, 0.601]	0.919 [0.912, 0.926]	0.665 [0.587, 0.743]	0.792	0.800	0.773	0.951
SVC SMOTE	0.587 [0.537, 0.637]	0.551 [0.506, 0.595]	0.918 [0.910, 0.926]	0.681 [0.613, 0.749]	0.782	0.684	0.637	0.959
SVC ADASYN	0.583 [0.527, 0.638]	0.549 [0.495, 0.603]	0.916 [0.908, 0.925]	0.666 [0.594, 0.738]	0.802	0.684	0.637	0.959
BRF	0.618 [0.593, 0.642]	0.689 [0.651, 0.726]	0.884 [0.871, 0.897]	0.610 [0.579, 0.641]	0.804	0.681	0.792	0.911
MLP SMOTE	0.620 [0.586, 0.653]	0.604 [0.567, 0.641]	0.922 [0.915, 0.929]	0.691 [0.647, 0.735]	0.972	0.660	0.640	0.943
MLP ADASYN	0.611 [0.560, 0.662]	0.610 [0.552, 0.668]	0.921 [0.913, 0.928]	0.643 [0.593, 0.694]	0.977	0.658	0.640	0.943
RF SMOTE	0.605 [0.554, 0.655]	0.578 [0.523, 0.634]	0.922 [0.914, 0.930]	0.682 [0.618, 0.745]	0.878	0.648	0.613	0.951
HGB ADASYN	0.559 [0.508, 0.611]	0.546 [0.500, 0.593]	0.917 [0.909, 0.924]	0.605 [0.536, 0.675]	0.899	0.641	0.603	0.951
Logit SMOTE	0.609 [0.565, 0.654]	0.576 [0.530, 0.623]	0.924 [0.917, 0.931]	0.688 [0.635, 0.742]	0.754	0.640	0.563	0.943
Logit ADASYN	0.610 [0.559, 0.661]	0.578 [0.526, 0.630]	0.923 [0.915, 0.931]	0.683 [0.622, 0.744]	0.748	0.627	0.563	0.943
HGB SMOTE	0.585 [0.534, 0.637]	0.574 [0.521, 0.627]	0.922 [0.915, 0.930]	0.646 [0.583, 0.709]	0.949	0.625	0.603	0.951
k-NN SMOTE	0.575 [0.532, 0.617]	0.549 [0.498, 0.600]	0.911 [0.904, 0.917]	0.688 [0.634, 0.741]	0.643	0.520	0.572	0.902
k-NN ADASYN	0.547 [0.514, 0.580]	0.529 [0.491, 0.567]	0.905 [0.899, 0.912]	0.639 [0.588, 0.689]	0.684	0.442	0.388	0.902


Matrices de confusión — top 3 modelos por F_1 macro test (multiclase)

Figura 4. Matrices de confusión de los tres mejores modelos en test por F_1 macro (multiclase). Eje x : clase predicha. Eje y : clase real.

ALP, ALB y BIL mostraron alta capacidad discriminativa respecto a la variable objetivo para ambas formulaciones. En general, no se identificaron variables claramente redundantes que justificaran selección directa.

V-B. Extracción lineal de características mediante análisis de componentes principales (PCA)

Con el objetivo de evaluar el impacto de la reducción lineal de dimensionalidad, se implementa PCA conservando el 90 % y 95 % de la varianza acumulada (correspondiente con entre 8 y 9 componentes), utilizando posteriormente estas representaciones reducidas en los modelos Random Forest y k-NN. En la formulación multiclase, ambos modelos presentan una disminución de desempeño respecto al espacio original de características. Sin embargo, conservar el 95 % de la varianza produce resultados consistentemente superiores al 90 %. En Random Forest, el F_1 Macro aumentó de 0.5060 a 0.6409, mientras que en k-NN pasó de 0.4810 a 0.5737. Esto sugiere que preservar una mayor cantidad de información resulta fundamental para mantener la separabilidad entre clases clínicas similares como Hepatitis, Fibrosis y Cirrhosis. La reducción dimensional afecta principalmente las clases minoritarias, mientras que la clase Blood Donor mantiene desempeños elevados. Esto evidencia que PCA conserva

adecuadamente la estructura global de los datos, pero puede eliminar patrones discriminativos relevantes para distinguir estados intermedios de enfermedad hepática. En la formulación binaria, los resultados mejoran significativamente para ambos modelos. En este caso, la reducción dimensional no deteriora la capacidad predictiva debido a que la separación entre sano y enfermo representa un problema menos complejo. Random Forest alcanzó un F_1 Macro de 0.9241 con PCA90, mientras que k-NN obtuvo su mejor desempeño con PCA95, alcanzando un F_1 Macro de 0.9317 y un recall de 1.0 para la clase Enfermo. En general, los resultados indican que el efecto de PCA depende de la complejidad diagnóstica del problema. Mientras en la formulación multiclase la reducción dimensional puede eliminar información clínica relevante, en la formulación binaria PCA actúa como un mecanismo efectivo de compactación y reducción de ruido, beneficiando especialmente a modelos basados en distancia como k-NN.


V-C. Extracción no lineal de características mediante aproximación y proyección de variedades uniformes (UMAP)

Como estrategia de reducción no lineal de dimensionalidad, se implementa UMAP. Se utilizaron configuraciones de 8 y 9 componentes como aproximación comparable a PCA90 y PCA95. Debido a incompatibilidades entre UMAP

Tabla IV

DESEMPEÑO DE LOS MODELOS EN LA FORMULACIÓN BINARIA (SANO VS. ENFERMO), ORDENADOS POR F_1 MACRO TEST (DESCENDENTE). LAS MÉTRICAS DE VALIDACIÓN SE REPORTAN COMO *media* [IC_{INF} , IC_{SUP}] AL 95 % CON T-STUDENT DE 4 G.L. SOBRE 5 FOLDS (STRATIFIEDKFOLD). F_1^+ ES EL F_1 DE LA CLASE *enfermo*. LOS LÍMITES SUPERIORES SE RECORTAN A 1.000 CUANDO LA APROXIMACIÓN T-STUDENT LOS EMPUJA POR ENCIMA DEL RANGO ADMISIBLE.

Modelo	Validación cruzada (con IC 95 %)				Train / Test			
	F_1 macro	Bal. Acc	F_1^+	AUC-ROC	F_1 Tr.	F_1 Te.	F_1^+ Te.	AUC Te.
k-NN SMOTE	0.833 [0.750, 0.916]	0.824 [0.732, 0.916]	0.705 [0.559, 0.852]	0.830 [0.735, 0.926]	0.956	0.948	0.909	0.992
RF SMOTE	0.936 [0.860, 1.000]	0.928 [0.833, 1.000]	0.887 [0.752, 1.000]	0.982 [0.952, 1.000]	1.000	0.945	0.903	0.996
RF ADASYN	0.935 [0.867, 1.000]	0.935 [0.835, 1.000]	0.886 [0.764, 1.000]	0.980 [0.945, 1.000]	0.995	0.945	0.903	0.998
Logit ADASYN	0.853 [0.800, 0.906]	0.889 [0.825, 0.953]	0.746 [0.654, 0.838]	0.916 [0.806, 1.000]	0.882	0.932	0.882	0.999
MLP ADASYN	0.898 [0.836, 0.959]	0.897 [0.811, 0.983]	0.820 [0.710, 0.929]	0.927 [0.825, 1.000]	0.973	0.932	0.882	0.997
SVC ADASYN	0.894 [0.828, 0.960]	0.909 [0.836, 0.982]	0.816 [0.700, 0.931]	0.974 [0.953, 0.994]	0.968	0.932	0.882	0.993
Logit SMOTE	0.877 [0.810, 0.944]	0.884 [0.801, 0.966]	0.784 [0.665, 0.904]	0.923 [0.809, 1.000]	0.898	0.928	0.875	0.996
MLP SMOTE	0.899 [0.829, 0.970]	0.897 [0.822, 0.971]	0.823 [0.699, 0.948]	0.929 [0.821, 1.000]	0.968	0.928	0.875	0.997
SVC SMOTE	0.903 [0.838, 0.967]	0.911 [0.840, 0.983]	0.829 [0.717, 0.942]	0.975 [0.955, 0.995]	0.973	0.913	0.849	0.996
k-NN ADASYN	0.827 [0.745, 0.909]	0.847 [0.765, 0.929]	0.700 [0.559, 0.840]	0.909 [0.827, 0.990]	0.920	0.917	0.857	0.992

Matrices de confusión — top 3 modelos por F_1 macro test (binario)Figura 5. Matrices de confusión de los tres mejores modelos en test por F_1 macro (binario). Eje x : clase predicha. Eje y : clase real.

y ADASYN, todos los experimentos se realizaron utilizando SMOTE. En la formulación multiclase, UMAP presentó un desempeño considerablemente inferior al obtenido con PCA y con el espacio original de características. Tanto Random Forest como k-NN alcanzaron valores de F_1 Macro cercanos a 0.31 y Balanced Accuracy alrededor de 0.28, evidenciando dificultades importantes para reconocer correctamente las clases minoritarias. Aunque la precisión se mantuvo cercana a 0.89, se observaron valores muy bajos de recall y F_1 para categorías como *Hepatitis* y *suspect Blood Donor*. Además, todos los experimentos mostraron diferencias extremadamente altas entre entrenamiento y prueba, con valores de F_1 Macro cercanos a 0.98 en entrenamiento y aproximadamente 0.31 en prueba, indicando un sobreajuste severo y una pobre capacidad de generalización. En la formulación binaria, los resultados mejoraron debido a la menor complejidad del problema similar a como sucede con PCA. Random Forest alcanzó un F_1 Macro de 0.7362 utilizando 9 componentes, mientras que k-NN obtuvo resultados similares entre configuraciones. Sin embargo, el recall para la clase *Enfermo* permaneció relativamente bajo, indicando que varios pacientes enfermos continuaron siendo clasificados incorrectamente como sanos.

V-D. Resultados de análisis de extracción de características

Los análisis de correlación e información mutua mostraron que, aunque existen algunas relaciones entre variables, no se evidencian niveles severos de colinealidad ni redundancias extremas entre predictores. Adicionalmente, los experimentos de extracción lineal y no lineal de características mediante PCA y UMAP no produjeron mejoras consistentes respecto al desempeño obtenido utilizando el conjunto original de variables.

En particular, PCA generó una ligera pérdida de capacidad discriminativa en el escenario multiclase, mientras que UMAP presentó problemas importantes de sobreajuste y generalización. Estos resultados sugieren que el conjunto original de características conserva información relevante para la separación de las clases clínicas y que, **para este problema específico, no se observa una oportunidad clara de reducción dimensional sin afectar el desempeño predictivo.**

Lo anterior indica que las variables originales poseen un aporte discriminativo complementario, especialmente para la identificación de clases minoritarias asociadas a estados intermedios de enfermedad hepática.

Tabla V
RESUMEN DE RESULTADOS OBTENIDOS CON EXTRACCIÓN DE CARACTERÍSTICAS MEDIANTE PCA Y UMAP.

Método	Configuración	Modelo	Formulación	F_1 Macro	Observaciones
PCA	90 % varianza	RF + SMOTE	Multiclase	0.5060	Pérdida moderada de separabilidad en clases minoritarias.
PCA	95 % varianza	RF + SMOTE	Multiclase	0.6409	Mejor desempeño multiclase con PCA; menor pérdida de información.
PCA	90 % varianza	k-NN + ADASYN	Multiclase	0.4810	Bajo recall en clases intermedias de enfermedad.
PCA	95 % varianza	k-NN + ADASYN	Multiclase	0.5737	Mejora respecto a PCA90, especialmente en precisión macro.
PCA	90 % varianza	RF + SMOTE	Binaria	0.9241	Alta capacidad discriminativa entre sano y enfermo.
PCA	95 % varianza	RF + SMOTE	Binaria	0.8922	Ligera reducción respecto a PCA90.
PCA	90 % varianza	k-NN + ADASYN	Binaria	0.8755	Recall perfecto para la clase enfermo.
PCA	95 % varianza	k-NN + ADASYN	Binaria	0.9317	Mejor resultado binario con reducción lineal.
UMAP	8 componentes	RF + SMOTE	Multiclase	0.3132	Sobreajuste severo y baja generalización.
UMAP	9 componentes	RF + SMOTE	Multiclase	0.3202	Leve mejora, pero desempeño insuficiente.
UMAP	8 componentes	k-NN + SMOTE	Multiclase	0.3069	Recall muy bajo en clases minoritarias.
UMAP	9 componentes	k-NN + SMOTE	Multiclase	0.3069	Sin mejoras respecto a 8 componentes.
UMAP	8 componentes	RF + SMOTE	Binaria	0.6735	Mejora frente al escenario multiclase.
UMAP	9 componentes	RF + SMOTE	Binaria	0.7362	Mejor resultado binario con UMAP.
UMAP	8 componentes	k-NN + SMOTE	Binaria	0.6735	Bajo recall para pacientes enfermos.
UMAP	9 componentes	k-NN + SMOTE	Binaria	0.6735	Sin diferencias relevantes frente a 8 componentes.




Figura 6. Curvas ROC superpuestas para los cinco mejores modelos (binario). Eje x : tasa de falsos positivos. Eje y : tasa de verdaderos positivos. AUC reportado en la leyenda.

VI. DISCUSIÓN Y CONCLUSIONES

Los resultados obtenidos muestran que el problema de clasificación de hepatitis C presenta comportamientos significativamente distintos entre la formulación multiclase y la formulación binaria. En el escenario multiclase, el principal desafío corresponde al fuerte desbalance entre categorías y a la similitud clínica entre estados intermedios de enfermedad como Hepatitis, Fibrosis y Cirrrosis. Aunque varios modelos alcanzaron altos valores de accuracy, las métricas macro evidenciaron dificultades para generalizar correctamente sobre las clases minoritarias, confirmando que la precisión global no resulta suficiente para evaluar este problema.

En términos generales, los mejores resultados multiclase se obtuvieron con Random Forest combinado con ADASYN, alcanzando un F_1 macro cercano a 0.80 y una precisión balanceada de 0.77. Este comportamiento coincide parcialmente con lo reportado en [6], donde los modelos basados en ensambles y




Figura 7. Matriz de correlación lineal de Pearson para el conjunto de características.




Figura 8. Información mutua entre las características y la variable respuesta (formulación multiclase).

estrategias de sobremuestreo mostraron mayor robustez frente al desbalance de clases. Asimismo, los resultados respaldan las observaciones de [5], donde técnicas de balanceo similares permitieron mejorar el reconocimiento de clases minoritarias en problemas clínicos.




Figura 9. Información mutua entre las características y la variable respuesta (formulación binaria).




Figura 10. Varianza explicada acumulada vs número de componentes principales, en este caso para el rango 90-95 % de varianza explicada se corresponde a 8-9 componentes principales.

La formulación binaria produjo resultados considerablemente superiores. La agrupación entre pacientes sanos y pacientes con enfermedad hepática redujo la complejidad del espacio de decisión y permitió obtener valores de F_1 macro superiores a 0.93 y AUC-ROC cercanos a 1.0 en modelos como Random Forest y k-NN. Estos resultados son coherentes con la literatura revisada, donde la mayoría de trabajos reportan desempeños elevados al simplificar el problema a dos categorías clínicas.

Respecto al análisis de características, los experimentos de correlación e información mutua mostraron que las variables poseen aporte discriminativo complementario y que no existen evidencias fuertes de redundancia extrema. Esto se confirmó experimentalmente mediante PCA y UMAP. En el caso de PCA, aunque la formulación binaria mantuvo desempeños competitivos, en multiclase se observó pérdida de capacidad discriminativa al reducir dimensionalidad. Por su parte, UMAP presentó problemas importantes de sobreajuste y pobre generalización, especialmente en las clases minoritarias. En conjunto, estos resultados indican que el conjunto original de variables contiene información relevante que no puede reducirse agresivamente sin afectar el desempeño predictivo.

Finalmente, los resultados obtenidos permiten concluir que los métodos de ensamble combinados con estrategias adecuadas de balanceo constituyen la alternativa más efectiva para

este conjunto de datos. Sin embargo, también evidencian que la identificación precisa de estados intermedios de enfermedad hepática continúa siendo una tarea compleja debido al reducido número de ejemplos y a la superposición clínica entre categorías. Como trabajo futuro, podrían explorarse enfoques híbridos, métodos de selección automática de características y estrategias de aprendizaje profundo o AutoML similares a las propuestas en [4] y [2].

REFERENCIAS

- [1] R. Lichtinghagen, F. Klawonn y G. Hoffmann, "HCV Data," *UCI Machine Learning Repository*, 2020, doi: 10.24432/C5D612.
- [2] A. Sharma, T. Khade y S. M. Satapathy, "A cross dataset meta-model for hepatitis C detection using multi-dimensional pre-clustering," *Scientific Reports*, vol. 15, no. 1, Art. no. 7278, 2025, doi: 10.1038/s41598-025-91298-0.
- [3] M. Goh, "Predicting hepatitis patient survivability using UCI dataset," *Towards Data Science*, 2020. [En línea]. Disponible en: <https://towardsdatascience.com/predicting-hepatitis-patient-survivability-uci-dataset-71982aa6775d/>. [Accedido: 26-abr-2026].
- [4] M. Değer y A. Can, "Automated machine learning for hepatitis C prediction," *Computers in Biology and Medicine*, vol. 179, Art. no. 109897, 2025, doi: 10.1016/j.compbiomed.2025.109897.
- [5] R. A. Charisma y A. Maulina, "Robust classification of hepatitis C: Leveraging random forest and hybrid SMOTE-ENN for imbalanced dataset," en *Proc. 7th Int. Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, Yogyakarta, Indonesia, 2024, pp. 210–216, doi: 10.1109/ISRITI64779.2024.10963586.
- [6] M. F. Hossain, K. J. Moumi y M. Dey, "Prediction of hepatitis C-related liver diseases through ensemble learning: A comprehensive analysis using the UCI HCV dataset," en *Proc. 13th Int. Conf. on Frontiers of Intelligent Computing: Theory and Applications (FICTA)*, London, U.K., 6–7 jun. 2025, en prensa.