

Formulación de un sistema de clasificación supervisada para hepatitis C en humanos

Jefferson Andrés Espejo-Goez, Diego Alejandro Vásquez-Aguilar
Modelos y Simulación de Sistemas II

Resumen—Este trabajo aborda la formulación inicial de un sistema de apoyo para la clasificación de hepatitis C a partir del conjunto de datos HCV del repositorio UCI [1]. El objetivo es definir con precisión el problema, describir la base de datos y justificar el paradigma de aprendizaje seleccionado. El conjunto contiene 615 registros, 12 variables predictoras de tipo demográfico y bioquímico, una variable objetivo con cinco categorías clínicas y valores faltantes concentrados en un subconjunto pequeño de atributos. A partir de estas características se plantea una tarea de clasificación supervisada, principalmente multiclase, con una formulación binaria complementaria para contrastar resultados con parte de la literatura. La estrategia inicial contempla eliminación de índices auxiliares, codificación explícita de variables categóricas, imputación robusta por mediana en atributos numéricos y tratamiento cuidadoso del desbalance de clases.

Index Terms—hepatitis C, machine learning, aprendizaje supervisado, clasificación, datos clínicos, UCI

I. INTRODUCCIÓN

La hepatitis C es una enfermedad de interés clínico debido a que puede evolucionar desde estados iniciales con pocos síntomas hasta fibrosis, cirrosis y daño hepático severo. En este contexto, el uso de modelos de aprendizaje automático sobre datos de laboratorio puede servir como herramienta de apoyo para identificar patrones que faciliten la clasificación de pacientes, la priorización de estudios y la exploración de factores asociados a la enfermedad.

II. DESCRIPCIÓN DEL PROBLEMA

II-A. Contexto del problema

El problema de interés consiste en clasificar registros de pacientes potenciales donantes de sangre a partir de variables demográficas y pruebas bioquímicas relacionadas con función hepática. Una solución basada en aprendizaje automático es pertinente porque el conjunto de datos contiene etiquetas conocidas, variables clínicas estructuradas y patrones no triviales entre biomarcadores, lo que permite construir modelos de clasificación con potencial utilidad como apoyo a la decisión.

La utilidad práctica de este tipo de sistema radica en tres puntos. Primero, puede apoyar el tamizaje inicial de pacientes con alteraciones compatibles con hepatitis C. Segundo, permite comparar qué tan informativas son distintas pruebas de laboratorio en la separación de clases clínicas. Tercero, ofrece una base reproducible para analizar si una formulación binaria o multiclase resulta más conveniente bajo condiciones

Tabla I
VARIABLES DEL DATASET HCV

Variable	Tipo	Descripción
Category	Categ.	Diagnóstico o condición clínica del registro.
Age	Num.	Edad del paciente.
Sex	Categ.	Sexo reportado en el registro.
ALB	Num.	Albúmina.
ALP	Num.	Fosfatasa alcalina.
ALT	Num.	Alanina aminotransferasa.
AST	Num.	Aspartato aminotransferasa.
BIL	Num.	Bilirrubina.
CHE	Num.	Colinesterasa.
CHOL	Num.	Colesterol.
CREA	Num.	Creatinina.
GGT	Num.	Gamma-glutamyl transferasa.
PROT	Num.	Proteínas totales.

de desbalance y presencia de datos faltantes. En cualquier caso, el modelo debe entenderse como una herramienta de apoyo y no como un sustituto del criterio médico.

II-B. Composición de la base de datos

Se utilizará el conjunto *HCV data* del repositorio UCI [1]. En el archivo CSV validado para este proyecto se identifican 615 registros y 13 columnas útiles: 12 variables predictoras y la variable objetivo *Category*. En la exportación original también puede aparecer una primera columna vacía asociada al índice del archivo; dicha columna no contiene información clínica y será eliminada antes del modelado.

La Tabla I resume las variables del conjunto. Las variables *Age* y *Sex* corresponden a información demográfica, mientras que las demás representan pruebas bioquímicas relacionadas con el estado del hígado y el metabolismo del paciente.

La variable objetivo presenta cinco categorías clínicas:

- 0=Blood Donor: 533 registros.
- 0s=suspect Blood Donor: 7 registros.
- 1=Hepatitis: 24 registros.
- 2=Fibrosis: 21 registros.
- 3=Cirrhosis: 30 registros.

Esta distribución evidencia un desbalance severo, ya que la clase *Blood Donor* concentra la gran mayoría de observaciones. Por tanto, cualquier metodología posterior debe evitar que la exactitud global esconda un mal desempeño sobre las clases minoritarias.

En cuanto a valores faltantes, el archivo presenta ausencias en cinco atributos numéricos: *ALB* (1), *ALP* (18), *ALT* (1), *CHOL* (10) y *PROT* (1). No se observan faltantes en la variable

objetivo ni en los demás atributos. Dado que se trata de variables continuas de laboratorio y el conjunto contiene clases pequeñas, se propone imputación por la mediana calculada exclusivamente sobre el conjunto de entrenamiento. Esta decisión busca reducir la sensibilidad a valores extremos y evitar fuga de información en las etapas de validación o prueba.

Respecto a la codificación, se adoptará el siguiente criterio:

- La columna índice vacía del CSV, si aparece, se eliminará.
- Sex se codificará de forma binaria para el modelado.
- Category se tratará como variable nominal. Para uso computacional se asignarán etiquetas enteras a cada clase, pero dichas etiquetas funcionarán solo como identificadores y no como valores ordinales continuos.
- Las variables bioquímicas se conservarán como numéricas continuas.

II-C. Paradigma de aprendizaje y justificación

El problema se formula como una tarea de clasificación supervisada porque cada registro cuenta con una etiqueta conocida en la variable `Category`. La naturaleza tabular del conjunto, el número moderado de variables y la combinación de atributos demográficos y clínicos hacen apropiado el uso de clasificadores supervisados tradicionales y modernos.

La formulación principal del proyecto será **multiclase**, ya que respeta la estructura original del dataset y permite distinguir entre donantes, pacientes sospechosos, pacientes con hepatitis, pacientes con fibrosis y pacientes con cirrosis. Esta formulación es más exigente, pero también más fiel al problema clínico representado por los datos. De forma complementaria, se considerará una formulación **binaria** en la que `Blood Donor` y `suspect Blood Donor` se agrupen como clase de pacientes sin enfermedad hepática, mientras que `Hepatitis`, `Fibrosis` y `Cirrhosis` se agrupen como clase de pacientes con enfermedad hepática. Esta segunda formulación será útil para comparar los resultados propios con trabajos de la literatura que reducen el problema a dos clases.

Esta decisión metodológica se justifica por tres razones. Primero, el conjunto de datos ya proporciona etiquetas y una interpretación clínica clara para cada observación. Segundo, existe un desbalance importante entre clases, por lo que interesa evaluar modelos que puedan mantener sensibilidad sobre clases minoritarias sin degradar demasiado el desempeño global. Tercero, la coexistencia de una formulación multiclase y una binaria permite analizar el compromiso entre fidelidad clínica y facilidad de clasificación, lo que enriquece la interpretación posterior de resultados.

III. ESTADO DEL ARTE

El problema de predicción del estado de infección por hepatitis C ha sido ampliamente abordado en la literatura mediante técnicas de aprendizaje automático, principalmente bajo un paradigma de aprendizaje supervisado, utilizando datos clínicos estructurados como los del dataset HCV del repositorio UCI [1]. Los trabajos revisados consideran tanto formulaciones binarias como multiclase, dependiendo del nivel

de detalle clínico y del tratamiento del desbalance de clases previamente discutido.

En [2], se propone un enfoque híbrido que combina aprendizaje no supervisado y supervisado, donde se emplea una etapa de pre-clustering para transformar las características antes de aplicar un modelo de stacking. Esta estrategia busca mejorar la separabilidad de las clases mediante representaciones más informativas. La validación se realiza mediante experimentación comparativa, utilizando métricas como accuracy, mostrando mejoras frente a modelos tradicionales.

Por otro lado, en [3] se aborda la predicción de supervivencia en pacientes con hepatitis mediante un enfoque de clasificación supervisada, evaluando modelos como Regresión Logística, Árboles de Decisión, Random Forest y KNN. La metodología se basa en la división del conjunto de datos en entrenamiento y prueba, así como en el análisis del impacto del desbalance de clases. Se emplean métricas como accuracy, precision y recall, evidenciando que modelos de ensamble como Random Forest presentan mejor desempeño en datos balanceados.

En [4], se introduce un enfoque basado en Automated Machine Learning (AutoML), que automatiza la selección de modelos y la optimización de hiperparámetros dentro de un marco supervisado. La validación se realiza mediante comparación entre múltiples configuraciones, utilizando métricas estándar como accuracy, precision, recall y F1-score. Los resultados muestran que AutoML logra desempeños competitivos, reduciendo la necesidad de intervención manual en el proceso de modelado.

Asimismo, en [5] se comparan distintos modelos supervisados, incluyendo Regresión Logística, Árboles de Decisión, Random Forest, KNN y Gradient Boosting, aplicados a datos clínicos con desbalance de clases. El estudio incorpora técnicas de balanceo como SMOTE-ENN, combinadas con Random Forest, para mejorar la clasificación de clases minoritarias. La evaluación se realiza mediante métricas como accuracy, reportando mejoras significativas en el desempeño del modelo tras el tratamiento del desbalance.

Finalmente, en [6] se emplea directamente el dataset HCV del repositorio UCI, utilizando modelos de ensamble como Random Forest, AdaBoost y XGBoost, junto con técnicas de balanceo como ADASYN (Sobremuestreo Sintético Adaptativo). La metodología incluye preprocesamiento, normalización y evaluación comparativa entre modelos en escenarios balanceados y desbalanceados. Los resultados evidencian que Random Forest alcanza el mejor desempeño tras el balanceo de datos, mientras que XGBoost muestra robustez en escenarios desbalanceados.

En conjunto, los trabajos revisados coinciden en que los métodos de ensamble y las técnicas de balanceo de datos son fundamentales para mejorar el desempeño en la predicción de hepatitis C, especialmente debido al desbalance de clases y la complejidad de las relaciones entre variables clínicas.

REFERENCIAS

- [1] R. Lichtinghagen, F. Klawonn y G. Hoffmann, "HCV Data," *UCI Machine Learning Repository*, 2020, doi: 10.24432/C5D612.

- [2] A. Sharma, T. Khade y S. M. Satapathy, "A cross dataset meta-model for hepatitis C detection using multi-dimensional pre-clustering," *Scientific Reports*, vol. 15, no. 1, Art. no. 7278, 2025, doi: 10.1038/s41598-025-91298-0.
- [3] M. Goh, "Predicting hepatitis patient survivability using UCI dataset," *Towards Data Science*, 2020. [En línea]. Disponible en: <https://towardsdatascience.com/predicting-hepatitis-patient-survivability-uci-dataset-71982aa6775d/>. [Accedido: 26-abr-2026].
- [4] M. Değer y A. Can, "Automated machine learning for hepatitis C prediction," *Computers in Biology and Medicine*, vol. 179, Art. no. 109897, 2025, doi: 10.1016/j.compbiomed.2025.109897.
- [5] R. A. Charisma y A. Maulina, "Robust classification of hepatitis C: Leveraging random forest and hybrid SMOTE-ENN for imbalanced dataset," en *Proc. 7th Int. Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, Yogyakarta, Indonesia, 2024, pp. 210–216, doi: 10.1109/ISRITI64779.2024.10963586.
- [6] M. F. Hossain, K. J. Moumi y M. Dey, "Prediction of hepatitis C-related liver diseases through ensemble learning: A comprehensive analysis using the UCI HCV dataset," en *Proc. 13th Int. Conf. on Frontiers of Intelligent Computing: Theory and Applications (FICTA)*, London, U.K., 6–7 jun. 2025, en prensa.